

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение

высшего образования

«Национальный исследовательский

Нижегородский государственный университет им. Н.И. Лобачевского»

(ННГУ)

Институт информационных технологий, математики и механики

Кафедра: Алгебры, геометрии и дискретной математики

Направление подготовки: 01.03.01 – «Математика»

Профиль подготовки: «Общий профиль»

## КУРСОВАЯ РАБОТА

Тема:

«Нейронные сети Колмогорова-Арнольда»

Выполнил:

студент группы 3822Б1МА1

Никитин И. И.

---

ф.и.о.

---

подпись

Научный руководитель:

д.ф.-м.н., доцент, Золотых Н. Ю.

---

учёная степень, учёное звание, ф.и.о.

---

подпись

Нижний Новгород

2024

## Содержание

Введение .....	2
Глава 1. Теорема Колмогорова-Арнольда .....	3
1.1. Определения .....	3
1.2. Теоретическая основа .....	3
Глава 2. Нейронные сети Колмогорова-Арнольда .....	6
2.1. Структура нейронной сети .....	6
2.2. Оценка ограничений архитектуры .....	7
Заключение .....	9
Словарь терминов .....	10
Список литературы .....	11

## Введение

**Целью** данной работы является исследование нейронных сетей Колмогорова-Арнольда (**KAN**) и проверка утверждений, описанных в работе, в которой дано их первоначальное определение.

Для достижения цели необходимо было решить следующие **задачи**:

1. Исследовать теоретический фундамент **KAN** - теорему Колмогорова-Арнольда и её развитие;
2. Исследовать метод обобщения теоремы для определения структуры **KAN** по аналогии с **MLP**;
3. Проверить и разработать корректное утверждение о возможности предотвращения **COD** с помощью **KAN**.

**Объем и структура работы.** Курсовая работа состоит из введения, 2 глав и заключения. Полный объем работы составляет 11 страниц. Список литературы содержит 13 наименований.

## Глава 1. Теорема Колмогорова-Арнольда

### 1.1. Определения

*n*-мерный единичный (гипер)куб –  $\mathbb{I}^n := [0, 1]^n$ .

Сигмоидальная функция – функция  $\sigma : \mathbb{R} \rightarrow \mathbb{I} : \lim_{t \rightarrow -\infty} \sigma(t) = 0, \lim_{t \rightarrow \infty} \sigma(t) = 1$ .

Ступенчатая функция  $\sigma$ -типа – функция вида  $f(x) = \sum_{i=1}^k a_i \sigma(b_i x + c_i)$ .

Разбиение единицы – Набор неотрицательных функций  $\{f_\beta : M \rightarrow \mathbb{I}\}$  на топологическом пространстве  $M$ , такой, что  $\forall x \in M : \sum_\beta f_\beta(x) = 1$ .

### 1.2. Теоретическая основа

**Лемма 1.1.** (Колмогоров, 1956): Любая  $f \in C(\mathbb{I}^2)$  может быть равномерно приближена формулой вида:

$$P_1(x)Q(R_1(x) + y) + P_2(x)Q(R_2(x) + y), \quad (1.1)$$

причём  $P_1, P_2, Q, R_1, R_2 \in C(\mathbb{R})$ .

*Схема доказательства.*

Зафиксируем  $\epsilon > 0$  и пусть

$$Q(x) = f(n\epsilon, y), \quad x \in [2n, 2n + 1]$$

– функция, «склеенная» из сечений  $f$ ;

$$R_1(x) = 4k, \quad \frac{x}{\epsilon} \in \left[-\frac{2}{3}, \frac{2}{3}\right] + 2k;$$

$$R_2(x) = 4k + 2, \quad \frac{x}{\epsilon} \in \left[-\frac{2}{3}, \frac{2}{3}\right] + 2k + 1.$$

– функции, переводящие  $x$  в отрезки в образе  $Q$ ;

$$P_1(x), P_2(x)$$

– периодические функции разбиения единицы. Тогда (1.1) приближает  $f$  так, как и требовалось.

□

Впоследствии результаты о возможности приближения непрерывных функций были усилены утверждениями о наличии *точных представлений* непрерывных функций:

**Лемма 1.2.** (Колмогоров, 1956 [1]): Любая  $f \in C(\mathbb{I}^n)$ ,  $n \geq 4$  выразима как суперпозиция функций трёх переменных  $g \in C(\mathbb{R}^3)$ .

**Лемма 1.3.** (Арнольд, 1957 [2]): Любая  $f \in C(\mathbb{I}^3)$  выразима как суперпозиция функций двух переменных  $g \in C(\mathbb{R}^2)$ .

В частности, Лемма 1.3 имеет важное

**Следствие.** (Гильберт, 1900, «13 проблема»): Любое уравнение 7 степени имеет решение, выразимое как суперпозиция непрерывных функций двух переменных.

И, наконец, основной результат, являющийся теоретическим фундаментом для рассматриваемой архитектуры нейронных сетей.

**Теорема 1.4.** (Колмогоров, 1957 [3]): Пусть  $f : \mathbb{I}^n \rightarrow \mathbb{R}$  – любая непрерывная функция  $n$  переменных. Тогда она выразима в виде:

$$f(x_1, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^n \phi_{q,p}(x_p) \right), \quad (1.2)$$

где  $\Phi_q \in C(\mathbb{R})$ ,  $\phi_{q,p} \in C(\mathbb{I}^n)$  – функции одной переменной, причём  $\phi_{p,q}$  можно выбрать независимо от  $f$ .

**Замечание.** В одной из формулировок теоремы функции  $\phi$  могут быть липшицевыми [4], однако уже для гладких функций  $\phi$  утверждение теоремы в общем случае неверно, даже если функция  $f$  гладкая. [5]

Теорема 1.4 в применении к нейронным сетям обсуждалась ранее, как в поддерживающих [6,7], так и в критикующих [8] работах. Один из основных аргументов критики основывается на том, что в теореме не указываются способы явно параметризовать функции  $\phi$ . Однако в более поздних статьях указаны как, оказывающийся практически полезным, способ использовать «аппроксимационный» вариант теоремы (в случае, когда приближения функций  $\phi$  известны) [6], так и конструктивный вариант доказательства самой теоремы [9].

Самым распространённым конструктивным методом построения функции аппроксимации на основе нейронной сети является метод обратного распространения ошибки («backpropagation»). Для его применения «передаточные функции» (в нашем случае это  $\Phi$  и  $\phi$ ) должны быть дифференцируемы, что существенно мешает точно представить функцию в виде, который предлагает Теорема 1.4. Однако, когда достаточно получить только приближение функции с допущением некоторой погрешности  $\epsilon$ , мы можем воспользоваться следующим результатом.

**Теорема 1.5.** (Куркова, 1991 [10]): Для любого  $n > 2$ ,  $\sigma : \mathbb{R} \rightarrow \mathbb{I}$  – сигмоидальной функции,  $f : \mathbb{I}^n \rightarrow \mathbb{R}$  – непрерывной функции и  $\epsilon > 0$  найдутся  $k \in \mathbb{N}$  и ступенчатые функции  $\sigma$ -типа  $\Phi_q$  и  $\phi_{q,p}$  такие, что для любого  $\mathbf{x} \in \mathbb{I}^n$ :

$$\left| f(x_1, \dots, x_n) - \sum_{q=1}^k \Phi_q \left( \sum_{p=1}^n \phi_{q,p}(x_p) \right) \right| < \epsilon. \quad (1.3)$$

Теорема 1.5 оказывается практически полезной для обучения сетей с помощью обратного распространения ошибки. Далее определим структуру нейронной сети по аналогии со структурой MLP, но используя вместо универсальной теоремы об аппроксимации теорему Колмогорова-Арнольда.

## Глава 2. Нейронные сети Колмогорова-Арнольда

### 2.1. Структура нейронной сети

Мы рассмотрим конструкцию сети, предложенную в работе [11].

**Определение.** *Слой* – матрица  $\Phi = \{\phi_{q,p}\}$ , где  $p = 1, 2, \dots, n_{\text{out}}$ ,  $q = 1, 2, n_{\text{in}}$ , а функции  $\phi$  имеют параметры, изменяемые в процессе обучения сети.

**Определение.** *Сигнатура сети* – для сети из  $L$  слоёв – упорядоченный набор  $(n_0, \dots, n_L) \subset \mathbb{N}$ , где  $n_i$  – число узлов в  $i$ -м слое сети.

Обозначим  $i$ -й узел в  $l$ -м слое сети как  $(l, i)$ , а его численное значение –  $x_{l,i}$ . Между слоями  $l$  и  $l + 1$  находится  $n_l * n_{l+1}$  функций  $\phi$ . Функцию, связывающую узел  $(l, i)$  с узлом  $(l + 1, j)$  обозначим

$$\phi_{l,j,i}, \quad l = 0, \dots, L - 1, \quad i = 1, \dots, n_l, \quad j = 1, \dots, n_{l+1}. \quad (2.1)$$

Аргумент функции  $\phi_{l,j,i}$  мы назовём «входным сигналом»  $x_{l,i}$ , а её значение – «выходным сигналом». Затем определим выходной сигнал узла  $(l + 1, j)$ :  $x_{l+1,j} = \sum_{i=1}^{n_l} \phi_{l,j,i}(x_{l,i})$ ,  $j = 1, \dots, n_{l+1}$ . В матричной записи выходной сигнал слоя сети будет иметь вид:

$$x_{l+1} = \Phi_l x_l = \begin{pmatrix} \phi_{l,1,1}(\cdot) & \dots & \phi_{l,1,n_l}(\cdot) \\ \vdots & & \vdots \\ \phi_{l,n_{l+1},2}(\cdot) & \dots & \phi_{l,n_{l+1},n_l}(\cdot) \end{pmatrix} x_l. \quad (2.2)$$

Полностью сеть, как и в случае с **MLP**, описывается как композиция слоёв. Для вектора входных данных  $x_0 \in \mathbb{R}^{n_0}$ :

$$\begin{aligned} \text{kan}(x_0) &= (\Phi_{L-1} \circ \Phi_{L-2} \circ \dots \circ \Phi_0) x_0, \\ \text{mlp}(x_0) &= (W_{L-1} \circ \sigma \circ W_{L-2} \circ \sigma \circ \dots \circ W_0) x_0. \end{aligned} \quad (2.3)$$

**Теорема 1.4** показывает, что внутренние функции образуют слой, где  $n_{\text{in}} = n$  и  $n_{\text{out}} = 2n + 1$ , а внешние функции образуют слой, где  $n_{\text{in}} = 2n + 1$  и  $n_{\text{out}} = 1$ . Таким образом, справедливо следующее

**Утверждение 2.1.** Выражения Колмогорова-Арнольда в уравнении (1.2) являются частным случаем сети из 2 слоёв.

*Доказательство.* Используя общую формулу:

$$\begin{aligned} f(x_0, \dots, x_{n_0}) &= (y_0, \dots, y_{n_L}), \\ y_{i_L} &= \sum_{i_{L-1}=1}^{n_{L-1}} \phi_{L-1,i_L,i_{L-1}} \left( \sum_{i_{L-2}=1}^{n_{L-2}} \phi_{L-2,i_{L-1},i_{L-2}} \left( \dots \left( \sum_{i_0=1}^{n_0} \phi_{0,i_1,i_0}(x_{i_0}) \right) \dots \right) \right) \end{aligned}$$

для сигнатуры  $(n_0, n_1, n_2) \equiv (n, 2n + 1, 1)$ ,  $i_1 \equiv q$ ,  $i_0 \equiv p$ ,  $\phi_{1,1,q} \equiv \Phi_q$ ,  $\phi_{0,q,p} \equiv \phi_{q,p}$ :

$$y_{i_2} = \sum_{i_1=1}^{n_1} \phi_{1,1,i_1} \left( \sum_{i_0=1}^{n_0} \phi_{0,i_1,i_0}(x_{i_0}) \right) \Rightarrow f(x_1, \dots, x_n) = y_1 = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^n \phi_{0,q,p}(x_p) \right).$$

□

## 2.2. Оценка ограничений архитектуры

Целью этого раздела является проверка предложения, данного в работе [11] о том, что предложенная структура нейронной сети позволяет избежать «проклятия размерности». В теории глубокого обучения этот термин может иметь следующее

**Определение.** *Проклятие размерности (COD)* – экспоненциальная зависимость количества параметров  $P(n)$  приближающей  $f(x_1, \dots, x_n)$  функции  $\tilde{f}$  от размерности многообразия, на котором задана функция  $f$ .

**Теорема 2.2.** Пусть  $f \in C(\mathbb{I}^n)$  имеет представление вида

$$f(x) \equiv \text{kan}(x) = (\Phi_{L-1} \circ \Phi_{L-2} \circ \dots \circ \Phi_0)x, \quad (2.4)$$

причём  $\Phi \in C^k(\mathbb{I})$ . Тогда KAN, соответствующая этому представлению, имеет  $P(n) = n^{2+2/k} \cdot \epsilon^{-1/k}$  параметров.

*Доказательство.* Разбиение  $[a, b] \subset \mathbb{R}$  осуществляется с помощью набора узлов  $\tau := (\tau_i)_1^{n+k}$ .

Определим мелкость разбиения  $|\tau|$  и размер сетки  $G$ :

$$|\tau| := \max_i \Delta \tau_i, \quad G := |\tau|^{-1}. \quad (2.5)$$

Пусть  $\Phi_q^G, \phi_{q,p}^G$  – приближения функций  $\Phi_q, \phi_{q,p}$  В-сплайнами. Тогда погрешность приближения функции  $f$  сетью будет ограничена следующим образом:

$$\|f - \text{kan}\| \leq \sum_{q=1}^{2n+1} (A_q(n, G) + B_q(G)), \quad (2.6)$$

$$A_q(n, G) = \left| \Phi_q \left( \sum_{p=1}^n \phi_{q,p} \right) - \Phi_q \left( \sum_{p=1}^n \phi_{q,p}^G \right) \right|, \quad B_q(G) = |\Phi_q - \Phi_q^G|.$$

Предположим, что функции  $\Phi_q - L_q$ -липшицевы, тогда:

$$A_q(n, G) = L_q \sum_{p=1}^n |\phi_{q,p} - \phi_{q,p}^G|. \quad (2.7)$$

Обозначим погрешности приближения и определим  $L$ :

$$\epsilon_\Phi = \max_{q,G} |\Phi_q - \Phi_q^G|, \quad \epsilon_\phi = \max_{q,p,G} |\phi_{q,p} - \phi_{q,p}^G|, \quad L = \max_q L_q, \quad (2.8)$$



тогда

$$\|f - \text{kan}\| \leq (2n + 1) \cdot (\epsilon_\Phi + L \cdot n \cdot \epsilon_\phi). \quad (2.9)$$

Таким образом,

$$\|f - \text{kan}\| \leq \epsilon \implies \epsilon_\Phi = O\left(\frac{\epsilon}{n}\right), \quad \epsilon_\phi = O\left(\frac{\epsilon}{n^2}\right). \quad (2.10)$$

Из теории приближений [12] известно, что для функции  $g \in C^k(\mathbb{I})$  В-сплайнами порядка  $k$  выполняется следующее неравенство типа Джексона — Стечкина:

$$\|g - g^G\| \leq \hat{C}_k \cdot G^{-k} \cdot \|D^k g\| = C_k \cdot G^{-k}, \quad (2.11)$$

где  $G$ -число функций в базисе сплайна. Отсюда получаем оценку для числа узлов  $G$ :

$$\epsilon_g \sim C_k G^{-k} \implies G \sim \sqrt[k]{\frac{C_k}{\epsilon_g}}. \quad (2.12)$$

Из (2.10) получаем, что

$$G_\Phi \sim \sqrt[k]{\frac{C_k}{\epsilon_\Phi}}, \quad G_\phi \sim \sqrt[k]{\frac{C_k}{\epsilon_\phi}} \implies G_\Phi \sim \sqrt[k]{\frac{C_k n}{\epsilon}}, \quad G_\phi \sim \sqrt[k]{\frac{C_k n^2}{\epsilon}}. \quad (2.13)$$

Оценим количество параметров в представлении:

$$\begin{aligned} P(n) &= (2n + 1)(G_\Phi + nG_\phi) \sim (2n + 1) \left( \sqrt[k]{\frac{C_k n}{\epsilon}} + n \sqrt[k]{\frac{C_k n^2}{\epsilon}} \right) \sim \\ &\sim (n^{1+1/k} + n^{2+2/k}) \cdot \epsilon^{-1/k} \sim \boxed{n^{2+2/k} \cdot \epsilon^{-1/k}}. \end{aligned} \quad (2.14)$$

□

Из теории приближений в многомерных пространствах [13] известно, что нижняя граница погрешности выражима в виде

$$\epsilon \geq C \cdot P(n)^{-k/n}. \quad (2.15)$$

Таким образом, если при  $n \rightarrow \infty$  фиксировать  $\epsilon$ , мы получим полиномиальный рост количества параметров:  $P(n) = n^{2+2/k}$ . Так действительно можно предотвратить COD. Однако, чтобы применение приближения было практически полезно, необходимо, чтобы  $\epsilon \rightarrow 0$  при  $n \rightarrow \infty$ , в силу того, что для пространств большой размерности данные становятся более разреженными. Поэтому, положив, к примеру,  $\epsilon = n^{-\alpha}$  мы будем иметь:

$$P(n) = O(n^{2+1/k+\alpha/k}). \quad (2.16)$$

Если взять  $\alpha = k \implies P(n) = O(n^3)$ , и COD не наблюдается. Но это ограничение на  $\alpha$  возможно только для малого класса функций, предположительно, гладких (например такого, в котором Теорема 1.4 даёт представление с количеством слагаемых  $S \ll n$ ). Для функций общего вида обыкновенно необходимо, чтобы  $\alpha \propto n$ , и COD сохраняется.

## Заключение

Основные результаты работы заключаются в следующем:

1. На основе анализа предыдущих исследований о способах определения нейронных сетей с помощью теоремы Колмогорова-Арнольда была разобрана работа [11]. Проверены основные, наиболее амбициозные утверждения статьи. Утверждения, подвергнутые сомнению, были исправлены, либо пояснены.
2. Определены перспективы дальнейшего исследования: формальное доказательство эквивалентности **MLP** и **KAN** со структурной (алгебраической) точки зрения. Также предлагается определить «место» рассмотренной архитектуры в алгебраической теории **CDL**.

## Словарь терминов

***CDL***: Categorical Deep Learning (Алгебраическая теория категориального глубокого обучения) 9

***COD***: Curse of Dimensionality (Проклятие размерности) 2, 7, 8

***KAN***: Kolmogorov-Arnold Network (Нейронная сеть Колмогорова-Арнольда) 2, 7, 9

***MLP***: Multi-layer perceptron (Многослойный перцептрон) 2, 5, 6, 9

## Список литературы

1. Колмогоров А. Н. О представлении непрерывных функций нескольких переменных суперпозициями непрерывных функций меньшего числа переменных. Доклады Академии Наук СССР, 1956. т. 108, № 2. сс. 179–182
2. Арнольд В. И. О функциях трёх переменных. Доклады Академии Наук СССР, 1957. т. 114, № 4. сс. 679–681
3. Колмогоров А. Н. О представлении непрерывных функций нескольких переменных в виде суперпозиций непрерывных функций одного переменного и сложения. Доклады Академии Наук СССР, 1957. т. 114, № 5. сс. 953–956
4. Sprecher D. On the Structure of Continuous Functions of Several Variables. American Mathematical Society, 1965. т. 115. сс. 340–355
5. Фридман Б. Л. Улучшение гладкости функций в теореме А. Н. Колмогорова о суперпозициях. Доклады Академии Наук СССР, 1967. т. 177. сс. 1019–1022
6. Kůrková V. Kolmogorov's Theorem Is Relevant. Neural Computation, 1991. т. 3, № 4. сс. 617–622
7. Ismayilova A., Ismailov V. On the Kolmogorov neural networks [электронный ресурс]. 2023. URL: <https://arxiv.org/abs/2311.00049>
8. Girosi F., Poggio T. Representation Properties of Networks: Kolmogorov's Theorem Is Irrelevant. Neural Computation, 1989. т. 1. сс. 465–469
9. Braun J., Griebel M. On a Constructive Proof of Kolmogorov's Superposition Theorem. Constructive Approximation, 2009. т. 30. сс. 653–675
10. Kůrková V. Kolmogorov's theorem and multilayer neural networks // Neural Networks. 1992. т. 5. сс. 501–506
11. Liu Z. и др. KAN: Kolmogorov-Arnold Networks [электронный ресурс]. 2024. URL: <https://arxiv.org/abs/2404.19756>
12. Boor C. de. A Practical Guide to Splines. 1978. сс. 145–155
13. Pinkus A. Approximation theory of the MLP model in neural networks. Acta Numerica, 1999. т. 8. сс. 143–195